



Decisão Sob Incerteza E Processos De Decisão De Markov (Mdp): Aplicação No Hospital Municipal Do Nzeto

Decision-making under uncertainty and Markov decision-making processes (MDP): Application at the Nzeto Municipal Hospital

Toma de decisiones en condiciones de incertidumbre y procesos de toma de decisiones de Markov (MDP): Aplicación en el Hospital Municipal de Nzeto.

¹ Ilda Luzia da Costa Pedro

² Mateus Padoca Calado Ph.D.

Resumo

O presente trabalho aborda a **tomada de decisão sob incerteza** no contexto hospitalar, com foco no **Hospital Municipal do Nzeto**, por meio da aplicação de **Processos de Decisão de Markov (MDP)**. A gestão hospitalar enfrenta desafios complexos devido à variabilidade na chegada de pacientes, à gravidade dos casos clínicos e à limitação de recursos, como leitos, profissionais de saúde e equipamentos. Decisões inadequadas podem comprometer tanto a eficiência operacional quanto a segurança dos pacientes.

O estudo teve como objetivo **modelar o hospital como um sistema de estados e ações**, definindo probabilidades de transição e recompensas associadas a cada decisão, permitindo determinar políticas ótimas que maximizem os resultados esperados. Nesta versão, o modelo foi aprimorado com **um componente de Machine Learning**, capaz de estimar o próximo estado do hospital com base nas decisões anteriores, fornecendo recomendações adaptativas em tempo real.

A metodologia adotada combina pesquisa aplicada e exploratória, coleta de dados hospitalares, revisão bibliográfica e simulação computacional, utilizando **algoritmos de Value Iteration e previsão de estados via ML** para orientar decisões de forma objetiva.



Os resultados demonstram que a aplicação de MDP permite: priorizar pacientes críticos, otimizar a ocupação de leitos, alocar recursos humanos e equipamentos de forma estratégica, simular cenários de alta demanda e fornecer **feedback imediato por meio de dashboards interativos com indicadores, alertas e gráficos**. Dessa forma, o estudo evidencia que os MDPs, combinados com modelos preditivos, são uma ferramenta eficaz para reduzir riscos, aumentar a eficiência operacional e melhorar a qualidade do atendimento hospitalar, contribuindo significativamente para a gestão moderna e baseada em dados do Hospital Municipal do Nzeto.

Palavras-chave: Processos de Decisão de Markov, decisão sob incerteza, gestão hospitalar, otimização de recursos, Machine Learning, Hospital Municipal do Nzeto.

¹ Mestrando em Engenharia Informática, Universidade Metodista de Angola. Luanda, Angola. Email. ildaluziadacostapedro@gmail.com

² Doutoramento em Engenharia Informática, Universidade Metodista de Angola. Luanda, Angola. Email. padoca@padoca.org.com

Abstract

This study addresses **decision-making under uncertainty** in the hospital context, focusing on the **Nzeto Municipal Hospital**, through the application of **Markov Decision Processes (MDPs)**. Hospital management faces complex challenges due to variability in patient arrivals, the severity of clinical cases, and limitations in resources such as beds, medical staff, and equipment. Inadequate decisions in this environment can compromise both operational efficiency and patient safety.

The study aims to **model the hospital as a system of states and actions**, defining transition probabilities and rewards for each decision, in order to determine **optimal policies that maximize expected outcomes**. In the current version, the model is enhanced with a **Machine Learning component** that predicts the hospital's next state based on prior decisions, providing adaptive, real-time recommendations to support decision-making.

The adopted methodology combines applied and exploratory research, hospital data collection, literature review, and computational simulation, employing **Value Iteration algorithms and predictive modeling** to guide decisions objectively.

The results demonstrate that applying MDPs enables: prioritization of critical patients, optimization of bed occupancy, strategic allocation of human and material resources, simulation of high-demand scenarios, and **real-time monitoring via an interactive dashboard with key performance indicators, alerts, and visualizations**. This study highlights that MDPs, when combined with predictive models, serve as an effective tool to **reduce risks, enhance operational efficiency, and improve quality of patient care**, significantly contributing to **modern, data-driven hospital management** at Nzeto Municipal Hospital.

Keywords: Markov Decision Processes, decision-making under uncertainty, hospital management, resource optimization, Machine Learning, Nzeto Municipal Hospital.

Resumen

El presente trabajo aborda la toma de decisiones bajo incertidumbre en el contexto hospitalario, con enfoque en el Hospital Municipal de Nzeto, mediante la aplicación de Procesos de Decisión de Markov (MDP). La gestión hospitalaria enfrenta desafíos

complejos debido a la variabilidad en la llegada de pacientes, la gravedad de los casos clínicos y la limitación de recursos, como camas, profesionales de la salud y equipos. Decisiones inadecuadas pueden comprometer tanto la eficiencia operativa como la seguridad de los pacientes.

El estudio tuvo como objetivo modelar el hospital como un sistema de estados y acciones, definiendo probabilidades de transición y recompensas asociadas a cada decisión, permitiendo determinar políticas óptimas que maximicen los resultados esperados. En esta versión, el modelo fue mejorado con un componente de Machine Learning, capaz de estimar el siguiente estado del hospital con base en decisiones anteriores, proporcionando recomendaciones adaptativas en tiempo real.

La metodología adoptada combina investigación aplicada y exploratoria, recolección de datos hospitalarios, revisión bibliográfica y simulación computacional, utilizando algoritmos de Value Iteration y predicción de estados mediante ML para orientar decisiones de manera objetiva.

Los resultados demuestran que la aplicación de MDP permite: priorizar pacientes críticos, optimizar la ocupación de camas, asignar recursos humanos y equipos de forma estratégica, simular escenarios de alta demanda y proporcionar retroalimentación inmediata mediante paneles interactivos con indicadores, alertas y gráficos. De esta forma, el estudio evidencia que los MDP, combinados con modelos predictivos, son una herramienta eficaz para reducir riesgos, aumentar la eficiencia operativa y mejorar la calidad de la atención hospitalaria, contribuyendo significativamente a una gestión moderna y basada en datos del Hospital Municipal de Nzeto.

Palabras clave: Procesos de Decisión de Markov, toma de decisiones bajo incertidumbre, gestión hospitalaria, optimización de recursos, Machine Learning, Hospital Municipal de Nzeto.

1. INTRODUÇÃO

Os hospitais, enquanto organizações complexas, operam em um ambiente caracterizado por elevada incerteza, variabilidade na demanda e necessidade constante de decisões rápidas e eficazes. A gestão hospitalar moderna exige não apenas competência clínica, mas também capacidade analítica para lidar com problemas de **alocação dinâmica de recursos**, priorização de pacientes segundo níveis de gravidade, gestão de fluxos de entrada e saída, e definição de políticas operacionais que garantam eficiência e equidade no atendimento. A imprevisibilidade associada à chegada de pacientes, à evolução do estado clínico e à disponibilidade de recursos torna o processo decisório particularmente desafiador.

Neste contexto, a **teoria da decisão sob incerteza** oferece um enquadramento metodológico robusto para modelar e otimizar sistemas complexos como os hospitalares. Entre as abordagens quantitativas disponíveis, os **Processos de Decisão de Markov (MDP)** destacam-se por permitir representar situações em que as decisões influenciam os estados futuros do sistema, considerando **probabilidades de transição e recompensas associadas** a diferentes políticas de ação. Essa modelagem é particularmente adequada para ambientes hospitalares, onde o estado do sistema pode ser definido pelo número de leitos ocupados, classificação de risco dos pacientes e disponibilidade de recursos humanos e materiais.

O presente trabalho propõe a aplicação de MDPs, integrada a **um modelo de previsão de próximos estados via Machine Learning**, como ferramenta de apoio à tomada de decisão estratégica no **Hospital Municipal do Nzeto**. O objetivo é desenvolver um modelo capaz de **auxiliar na gestão da ocupação de leitos, priorização de atendimentos e distribuição eficiente de recursos médicos limitados**, contribuindo para a maximização da eficiência operacional e minimização de riscos associados à indisponibilidade de atendimento adequado, especialmente para pacientes em estado crítico.

Ao integrar fundamentos teóricos da decisão sob incerteza com um estudo aplicado a uma instituição hospitalar concreta, esta investigação busca oferecer **uma contribuição metodológica e prática**, fornecendo uma ferramenta interativa que permite simular cenários, analisar políticas alternativas e fornecer recomendações adaptativas em tempo real. Dessa forma, reforça-se a importância da **modelação quantitativa e de**

ferramentas computacionais como instrumentos estratégicos na administração pública da saúde.

2. FUNDAMENTAÇÃO TEÓRICA

Segundo **Borba (2006)**, a gestão hospitalar não se limita apenas ao aspecto administrativo; envolve também o cuidado ao paciente, eficiência operacional, sustentabilidade financeira e conformidade regulatória.

Segundo **Cavalcante et al. (2020)**, a implantação da gestão da qualidade nas organizações de saúde tem como propósito central o desenvolvimento de políticas voltadas para a segurança do paciente, a compreensão dos requisitos necessários à melhoria do desempenho institucional, bem como a medição e identificação sistemática de oportunidades de aprimoramento.

Segundo **Prestes et al. (2020)**, a segurança do paciente consiste na implantação de ações que promovam a identificação de falhas e a melhoria contínua dos processos, evitando que o dano alcance o paciente.

2.1. DECISÃO SOB INCERTEZA

A decisão sob incerteza refere-se à seleção de ações em situações nas quais os resultados futuros não podem ser previstos com exatidão. Segundo Puterman (2014), esse tipo de decisão é característico de sistemas estocásticos, nos quais o decisor deve considerar múltiplos cenários possíveis e suas respectivas probabilidades de ocorrência. No contexto hospitalar, a incerteza manifesta-se de forma evidente em diversos aspetos do funcionamento diário.

Para lidar com esse cenário, torna-se necessário modelar explicitamente os estados possíveis do sistema hospitalar, associar probabilidades às transições entre esses estados e avaliar as consequências das ações disponíveis. Conforme defendido por Puterman (2014), essa abordagem permite que o decisor escolha ações que maximizem os benefícios esperados ou minimizem riscos e custos, mesmo diante de incerteza significativa.

2.2. PROCESSOS DE DECISÃO DE MARKOV(MDP)

Os Processos de Decisão de Markov constituem um framework formal amplamente utilizado para modelar problemas de decisão sequencial sob incerteza. De acordo com Puterman (2014), um MDP descreve um sistema dinâmico no qual as decisões são

tomadas em etapas sucessivas, assumindo que o estado atual contém toda a informação relevante para a evolução futura do sistema, propriedade conhecida como propriedade de Markov.

Segundo Puterman (2014), um MDP é definido por quatro componentes fundamentais sendo:

1. **Estados (S):** representam todas as configurações possíveis do sistema. No ambiente hospitalar, os estados podem refletir níveis de ocupação de leitos, número de pacientes críticos, disponibilidade de profissionais de saúde e de equipamentos médicos.
2. **Ações (A):** correspondem às decisões disponíveis ao decisor em cada estado, como admitir novos pacientes, transferir doentes entre unidades, abrir leitos adicionais ou reagendar procedimentos.
3. **Probabilidades de Transição (P):** descrevem a probabilidade de o sistema evoluir de um estado para outro após a execução de uma ação, capturando a incerteza associada à chegada de pacientes e à evolução clínica.
4. **Recompensas (R):** quantificam os benefícios ou custos associados a cada ação em determinado estado, podendo refletir eficiência operacional, qualidade do atendimento, satisfação dos pacientes ou penalizações por atrasos e desperdício de recursos.

O objetivo central de um MDP é determinar uma política ótima (π^*), isto é, uma regra que especifica a melhor ação a ser tomada em cada estado, de forma a maximizar a recompensa total esperada ao longo do tempo. Esse enquadramento torna os MDP particularmente adequados para apoiar decisões complexas na gestão hospitalar, conforme enfatizado por Puterman (2014).

2.3. POLÍTICA DE DECISÃO BASEADA EM VALOR ESPERADO

Uma política (π) define o comportamento do decisor, especificando qual ação deve ser tomada em cada estado do sistema. Segundo Puterman (2014), a avaliação da qualidade de uma política é realizada por meio da **função de valor**, que mede o retorno esperado associado à adoção dessa política a partir de um determinado estado.

A função de valor $V(s)$ representa a recompensa total esperada a partir do estado s , considerando uma política específica. A política ótima π^* é aquela que maximiza essa

função de valor para todos os estados do sistema, assegurando decisões consistentes e eficientes ao longo do tempo.

Um dos métodos mais utilizados para determinar a função de valor ótima é o algoritmo de **Value Iteration**, amplamente discutido por Puterman (2014). Esse método baseia-se na seguinte equação recursiva:

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V_k(s')]$$

onde:

- s representa o estado atual,
- a a ação escolhida,
- s' o estado seguinte,
- $P(s' | s, a)$ a probabilidade de transição,
- $R(s, a, s')$ a recompensa associada,
- γ o fator de desconto.

No contexto hospitalar, a aplicação desse método permite avaliar sistematicamente as consequências de diferentes decisões, apoiando a definição de políticas que promovam eficiência, redução de custos e melhoria da qualidade do atendimento, mesmo em cenários caracterizados por elevada incerteza.

2.4. FORMULAÇÃO DO PROBLEMA

A formulação do problema é essencial para a aplicação dos **Processos de Decisão de Markov (MDM ou MDP)**, pois permite representar matematicamente situações de decisão sequencial sob incerteza. Conforme Puterman (2014), o **problema de paragem ótima** (*optimal stopping problem*) descreve cenários nos quais o decisor deve escolher, em cada época de decisão, entre continuar ou interromper um processo estocástico em evolução.

A seguir, apresenta-se uma **formulação em termos de Processo de Decisão de Markov (MDP)** para o problema de paragem ótima.

2.4.1 Épocas de decisão (decision epochs):

$$T = \{1, 2, \dots, N\}, N \leq \infty$$

Para cada $t \in T$ é um instante em que se toma uma decisão sobre o estado do sistema.

Exemplo: cada hora ou cada chegada de paciente é uma época de decisão, onde o hospital decide se **admite ou não um paciente crítico**.

2.4.2 Estados:

$$S = S' \cup \{A\}$$

Onde:

- S' = todos os estados “ativos” (ex.: S_0, S_1, S_2 = ocupação dos leitos).
- A = estado absorvente, onde o processo termina (ex.: hospital fechou ou período de análise acabou).

Ou seja, enquanto não chegamos a A , o hospital continua tomando decisões sobre admissões.

E o estado absorvente A representa o final da análise ou o encerramento da operação.

2.4.3 Ações disponíveis:

$$A_s = \{C, Q\}, s \in S'$$

$$A_s = \{C\}, s = A$$

Onde:

- C = continuar (continuar o processo, ex.: avaliar chegada de pacientes e decidir admiti-los).
- Q = parar (ex.: decidir encerrar ou não admitir mais pacientes).

Ou seja, Se ainda houver leitos e pacientes chegando, o hospital pode **continuar a operar (C)** ou **decidir parar/adotar política de não admitir (Q)**. E no estado absorvente A , não há mais escolha (só existe C para “ficar parado”).

2.4.4 Recompensas:

Para $t = 1, \dots, N - 1$:

$$r_t(s, a) = \begin{cases} -f(s), & s \in S', a = C \\ g_t(s), & s \in S', a = Q \\ 0, & s = A \end{cases}$$

Onde:

- $f(s)$ = custo de manter o estado sativo (ex.: custo de ocupar leito, risco de não atender pacientes).
- $g_t(s)$ = ganho/recompensa por decidir parar no estado s .
- 0 = no estado absorvente A não há mais recompensa.

No período final ($t = N$):

$$r_N(s) = h(s)$$

A recompensa final do estado, como avaliação do desempenho total do sistema (ex.: número de pacientes atendidos, leitos liberados)

2.4.5 Probabilidades de transição:

$$p(j | s, a) = \begin{cases} p(j | s), & s \in S', j \in S', a = C \\ 1, & s \in S', j = A, a = Q \text{ ou } s = j = A, a = C, t < N \\ 0, & \text{caso contrário} \end{cases}$$

- Se você continuar (C), o próximo estado j depende da probabilidade do sistema evoluir (ex.: paciente recebe alta, novo paciente chega).
- Se você parar (Q), o próximo estado será sempre A (absorvente).
- Qualquer outra transição impossível tem probabilidade 0.

Segundo (Puterman, 2014), essa formulação é particularmente relevante em contextos hospitalares, onde decisões como **interromper admissões, transferir pacientes ou reagendar procedimentos** podem ser modeladas como problemas de paragem ótima, permitindo apoiar decisões eficientes mesmo em ambientes marcados por elevada incerteza.

2.5. APLICAÇÕES DE MODELOS DE MARKOV EM HOSPITAIS

Nos últimos anos, diversos estudos têm aplicado Modelos de Markov e Processos de Decisão de Markov (MDPs) para otimizar decisões hospitalares, desde alocação de leitos até o tratamento de pacientes com doenças crônicas. Esses modelos permitem lidar com a incerteza e a natureza sequencial das decisões médicas, fornecendo suporte para

políticas que minimizam tempo de espera, melhoram a utilização de recursos e aumentam a satisfação do paciente.

1. Controle de admissões eletivas

Nunes et al. (2009) aplicaram um MDP ao controle de admissões eletivas, com o objetivo de definir políticas ótimas que equilibrassem a utilização de recursos hospitalares e a variabilidade da demanda. Os resultados demonstraram que a modelação estocástica permite apoiar decisões operacionais complexas, reduzindo ineficiências associadas à sobrelotação ou subutilização de leitos.

Observação: O controle das admissões eletivas pode ser estruturado como um MDP, permitindo equilibrar a utilização de recursos hospitalares (Nunes et al., 2009).

2. Alocação de leitos hospitalares

Ramdurai (2023) propôs a utilização de um modelo baseado em Cadeias de Markov para otimizar a alocação de leitos hospitalares, demonstrando melhorias na taxa de ocupação e redução dos tempos de espera.

Observação: A utilização de cadeias de Markov na alocação de leitos permite prever padrões de ocupação e otimizar a gestão de recursos hospitalares (Ramdurai, 2023).

3. Programação de fornecimento de materiais médicos em emergências

Wang, Liang e Zhu (2021) aplicaram um MDP para a programação do fornecimento de materiais médicos de emergência durante crises de saúde pública. O modelo incorporou prioridades diferenciadas de hospitais e pacientes, mostrando como decisões sequenciais sob incerteza podem ser otimizadas para maximizar a eficiência e o atendimento adequado, evidenciando o potencial dos MDPs em situações críticas.

4. Decisões médicas sequenciais e tratamento de pacientes

Decisões sobre tratamentos médicos são frequentemente sequenciais e incertas, tornando os MDPs uma técnica adequada para modelar e resolver essas decisões dinâmicas e estocásticas (Schaefer, Bailey, Shechter, & Roberts, 2005).

No contexto da gestão hospitalar, muitas decisões operacionais, como alocação de leitos, priorização de pacientes ou distribuição de recursos médicos, envolvem incerteza sobre a evolução do estado dos pacientes e a disponibilidade de recursos. Processos de decisão de Markov oferecem uma abordagem adequada para modelar essas situações, permitindo

que gestores hospitalares analisem diferentes estratégias considerando tanto o estado atual do hospital quanto as probabilidades de transição para estados futuros (Schaefer, Bailey, Shechter, & Roberts, 2005).

Ao aplicar MDPs, é possível otimizar políticas de decisão que minimizem tempos de espera, melhorem a utilização de leitos e recursos, e garantam melhor atendimento aos pacientes críticos, considerando a natureza estocástica das chegadas e necessidades hospitalares.

2.6 APLICAÇÃO DE MDP NO HOSPITAL MUNICIPAL DO NZETO

Para apoiar o processo de tomada de decisão sob incerteza, foi desenvolvida uma aplicação computacional baseada em **Processos de Decisão de Markov (MDP)**. O sistema permite simular cenários realistas e avaliar políticas operacionais de forma sistemática, possibilitando aos gestores hospitalares analisar o impacto das ações sobre a ocupação de leitos, o uso de recursos e a urgência dos pacientes.

A aplicação foi implementada em **Python**, utilizando a biblioteca **Streamlit**, o que proporciona uma interface gráfica interativa. O usuário pode executar quatro ações principais: **admitir pacientes**, **transferir pacientes**, **abrir leitos adicionais** ou **reagendar atendimentos**, e observar os efeitos dessas decisões sobre os estados do hospital. A **Figura 1** apresenta o fluxo completo do sistema, desde a definição do estado inicial até a visualização dos resultados em dashboards interativos.

2.6.1 Objetivo da aplicação

O objetivo principal da aplicação é fornecer um ambiente de simulação interativo que permita:

- Avaliar o impacto de diferentes políticas sobre a ocupação de leitos e utilização de recursos;
- Medir eficiência operacional e satisfação dos pacientes em cenários diversos;
- Apoiar a tomada de decisão baseada em evidências, minimizando riscos de sobrecarga ou subutilização de recursos hospitalares.

Dessa forma, gestores podem explorar alternativas e identificar políticas que maximizem o desempenho global do hospital.

2.6.2 Implementação computacional

O sistema foi estruturado para operar em etapas sequenciais, com os seguintes elementos principais:

Estados (o, r, u): representam leitos ocupados (o), recursos disponíveis (r) e nível médio de urgência (u);

Foi definido limites iniciais para facilitar a simulação da aplicação, conforme imagem abaixo:

```
MAX_LEITOS = 100
MAX_RECURSOS = 25
MAX_URGENCIA = 35
```

Ações disponíveis: admitir, transferir, abrir leitos ou reagendar atendimentos;

```
acoes = ["admitir", "transferir", "abrir_leito", "reagendar"]
```

Transição de estados: para cada ação, calcula probabilidades de transição para estados futuros, refletindo a incerteza das decisões hospitalares;

```
def probabilidades_transicao(estado, acao):
    o, r, u = estado
    outcomes = []
    if acao == "admitir" and o < MAX_LEITOS:
        outcomes.append((o+1, r, max(0, min(MAX_URGENCIA, u))), 0.5))
        outcomes.append((o+1, r, max(0, min(MAX_URGENCIA, u+1))), 0.3))
        outcomes.append((o+1, r, max(0, min(MAX_URGENCIA, u-1))), 0.2))
    elif acao == "transferir" and o > 0:
        outcomes.append((o-1, r, max(0, min(MAX_URGENCIA, u))), 0.6))
        outcomes.append((o-1, r, max(0, min(MAX_URGENCIA, u+1))), 0.3))
        outcomes.append((o-1, r, max(0, min(MAX_URGENCIA, u-1))), 0.1))
    elif acao == "abrir_leito" and r > 0:
        outcomes.append((min(MAX_LEITOS, o+1), r-1, u), 1.0))
    elif acao == "reagendar":
        outcomes.append((o, r, max(0, min(MAX_URGENCIA, u))), 0.4))
        outcomes.append((o, r, max(0, min(MAX_URGENCIA, u+1))), 0.4))
        outcomes.append((o, r, max(0, min(MAX_URGENCIA, u-1))), 0.2))
    return outcomes
```

Função recompensa: avalia cada transição considerando eficiência, satisfação e custo da ação, segundo:

$$R = \text{Eficiência} + \text{Satisfação} - \text{Custo}$$

```
def recompensa(estado, acao, proximo_estado):
    o, r, u = proximo_estado
    eficiencia = o / MAX_LEITOS
    satisfacao = (MAX_URGENCIA - u) / MAX_URGENCIA
    custo_acao = 0.5 if acao in ["abrir_leito", "transferir"] else 0
    total = round(eficiencia + satisfacao - custo_acao, 2)
    return total, round(eficiencia,2), round(satisfacao,2), custo_acao
```

Valor esperado $Q(s,a)$: calcula o valor esperado de cada ação para orientar a política ótima, conforme:

$$Q(s, a) = \sum_{s'} P(s' | s, a) \cdot R(s, a, s')$$

```
def valor_esperado(estado, acao):
    outcomes = probabilidades_transicao(estado, acao)
    Q = 0
    for s_prime, prob in outcomes:
        r, _, _, _ = recompensa(estado, acao, s_prime)
        Q += prob * r
    return round(Q,2)
```

Modelo de previsão (ML): um modelo de regressão simples estima o próximo estado (o, r, u) com base no histórico de ações, permitindo sugestões adaptativas que se atualizam a cada decisão tomada;

```
def treinar_modelo_ml():
    if len(st.session_state.dados_ml) > 5:
        df = pd.DataFrame(st.session_state.dados_ml,
                           columns=["o", "r", "u", "acao", "o_next", "r_next", "u_next"])
        X = df[["o", "r", "u", "acao"]]
        st.session_state.modelo_o.fit(X, df["o_next"])
        st.session_state.modelo_r.fit(X, df["r_next"])
        st.session_state.modelo_u.fit(X, df["u_next"])
```

2.6.3 Estrutura do Modelo

Cada estado do sistema é representado pelo vetor (**Leitos ocupados, Recursos disponíveis, Urgência média**), e cada ação gera **transições probabilísticas** refletindo incertezas clínicas e administrativas. As ações e seus efeitos incluem:

- **Admitir:** incorpora um novo paciente, aumentando os leitos ocupados e influenciando a urgência média;
- **Transferir:** movimenta pacientes para outro setor, liberando leitos;
- **Abrir leito:** cria disponibilidade adicional, reduzindo recursos disponíveis;
- **Reagendar:** adia atendimentos, afetando a urgência média.

Dashboard interativo: apresenta indicadores em tempo real, alertas operacionais, histórico de decisões, gráficos de evolução do valor esperado e recomendações do modelo de ML.

```
st.markdown(
    """
    <div style='text-align: center; margin-bottom: 30px;'>
        <h1 style='color: #0066cc; margin-bottom: 10px;'> 🏥 Hospital MDP Dashboard</h1>
        <p style='color: #666;'>Decisão sob Incerteza e Processos de Decisão de Markov (MDP)</p>
        <p style='color: #999; font-size: 12px;'>Hospital Municipal do Nzeto</p>
    </div>
    """,
    unsafe_allow_html=True
)


# ----- Indicadores em Cards Melhorados -----
ef_total, sat_total, _, custo_total = recompensa(estado, "admitir", estado)

# Get color for each metric
color_leitos, _ = obter_cor_status(estado[0], MAX_LEITOS)
color_recursos, _ = obter_cor_status(estado[1], MAX_RECURSOS)
color_urgencia, _ = obter_cor_status(estado[2], MAX_URGENCIA, reverso=True)
color_exec, _ = obter_cor_status(ef_total, 1)
color_sat, _ = obter_cor_status(sat_total, 1, reverso=True)
color_cost, _ = obter_cor_status(custo_total, 1, reverso=True)
```

2.6.4. Arquitetura e Fluxo do Sistema

O sistema foi estruturado para operar em etapas sequenciais, desde a definição do estado inicial até a visualização dos resultados em dashboards interativos. A Figura 1 apresenta o **fluxo completo do sistema**, detalhando cada etapa da simulação e da tomada de decisão.

Figura 1 - Fluxo do Sistema




Fonte 1 - Modelado por IA

1. **Estado Atual (o, r, u):** Representa a situação do hospital em termos de leitos ocupados (o), recursos disponíveis (r) e nível médio de urgência (u).
2. **Ações Disponíveis:** O sistema pode executar quatro ações:
 - Admitir pacientes
 - Transferir pacientes
 - Abrir leitos adicionais
 - Reagendar atendimentos

As **ações disponíveis** incluem: **admitir pacientes, transferir pacientes, abrir leitos adicionais e reagendar atendimentos**, representando decisões operacionais reais, conforme ilustra o deagrama que se segue:

Figura 2 - Diagrama de estados do MDP com 8 estados representando a evolução do hospital conforme diferentes decisões.

3.



Fonte 2 - Criado pelo Autor. Cada círculo representa um estado do hospital; as setas representam ações possíveis com suas probabilidades associadas. As cores indicam a ação executada (admitir, transferir, abrir leito, reagendar).

4. Transição de Estados: Para cada ação, o sistema calcula probabilidades de transição para estados futuros, refletindo a incerteza das decisões hospitalares.

A tabela a seguir resume os principais estados do hospital modelados no MDP, considerando leitos ocupados, recursos disponíveis e urgência média dos pacientes. Para cada estado, são apresentadas as ações disponíveis (admitir, transferir, abrir leito e reagendar), os possíveis próximos estados resultantes de cada ação e as probabilidades associadas a cada transição.

Cada linha representa uma transição probabilística, permitindo ao leitor visualizar de forma clara como diferentes decisões impactam o sistema hospitalar. Essa representação complementar ao diagrama de estados ajuda a compreender a dinâmica do modelo e a base para a análise de políticas de decisão sob incerteza.

5. Tabela 1 - Resumo dos Estados e Transições do Hospital

Estado Atual	Ação	Próximo Estado	Probabilidade
q0	Admitir	q1	0.5
q0	Admitir	q2	0.3
q0	Admitir	q3	0.2
q0	Transferir	q0	0.6
q0	Transferir	q1	0.3
q0	Transferir	q2	0.1

q1	Abrir_leito	q4	1.0
q1	Reagendar	q1	0.4
q1	Reagendar	q2	0.4
q1	Reagendar	q0	0.2
q2	Admitir	q3	0.5
q2	Transferir	q0	0.5
q3	Abrir_leito	q5	1.0
q3	Reagendar	q3	0.6
q3	Reagendar	q4	0.4
q4	Admitir	q5	0.7
q4	Transferir	q3	0.3
q5	Abrir_leito	q6	1.0
q5	Reagendar	q5	0.5
q5	Reagendar	q6	0.5
q6	Admitir	q7	0.6
q6	Transferir	q5	0.4
q7	Reagendar	q7	1.0

6. *Fonte 3 - Elaborado pelo Autor. Cada linha indica um estado do hospital, as ações disponíveis e os próximos estados possíveis com suas respectivas probabilidades*

7. **Função Recompensa:** Avalia cada transição considerando a eficiência do uso dos leitos, a satisfação dos pacientes e o custo da ação realizada, conforme a fórmula:

$$R = \text{Eficiência} + \text{Satisfação} - \text{Custo}$$

8. **Cálculo do Valor Esperado $Q(s, a)$:** O valor esperado de cada ação é calculado para orientar a política ótima, utilizando:

$$Q(s, a) = \sum_{s'} P(s' | s, a) \cdot R(s, a, s')$$

9. **Próximo Estado:** Atualiza o estado do sistema com base na ação selecionada e na amostra probabilística das transições.

10. **Resultados & Dashboard:** Exibe indicadores, histórico de decisões e gráficos interativos que permitem ao usuário acompanhar a evolução da simulação em tempo real.

2.6.5 Resumo do funcionamento

1. utilizador define o estado inicial do hospital, representado pelo vetor (leitos ocupados, recursos disponíveis e nível de urgência média);
2. O sistema apresenta as ações disponíveis e, ao selecionar uma delas, simula a transição para novos estados com base em distribuições de probabilidade pré-definidas;
3. A função de recompensa avalia o estado resultante da ação, considerando eficiência, satisfação e custo operacional;
4. O valor esperado $Q(s,a)$ é calculado como média ponderada das recompensas associadas às possíveis transições, sendo utilizado como métrica de comparação entre ações no estado atual;
5. Um modelo de regressão linear (Machine Learning) é treinado com o histórico de interações e utilizado para estimar o próximo estado do sistema, funcionando como suporte preditivo e auxiliar na análise de tendências;
6. O dashboard atualiza em tempo real os indicadores de desempenho, histórico de decisões, alertas operacionais e visualizações gráficas, permitindo monitorização contínua do comportamento do sistema.
7. O sistema permite explorar cenários diversos, analisar políticas alternativas e identificar situações críticas, auxiliando na otimização da alocação de recursos e na gestão hospitalar.

2.6.6 Transição para os resultados

A aplicação fornece uma base para análise exploratória do comportamento de um sistema hospitalar sob incerteza, permitindo:

- Analisar diferentes cenários de ocupação de leitos, recursos disponíveis e níveis de urgência dos pacientes;
- Avaliar o impacto de diferentes ações com base no histórico de decisões e respetivas recompensas observadas;
- Comparar o valor esperado das ações $Q(s,a)$, obtido por simulação estocástica, com previsões do modelo de Machine Learning para o próximo estado do sistema;

- Observar padrões de comportamento emergentes no sistema hospitalar e identificar situações críticas de operação;
- Apoiar a análise da gestão de recursos hospitalares com base em dados simulados e métricas de desempenho operacional.

2.6.7. Pilha tecnológica e arquitetura computacional do sistema

A implementação do sistema de simulação do Hospital Municipal do Nzeto foi desenvolvida com base numa arquitetura computacional orientada à análise estocástica, visualização interativa e aprendizagem supervisionada. O sistema foi inteiramente implementado em Python, devido à sua forte adoção em ciência de dados e modelação de sistemas probabilísticos.

A interface gráfica foi construída utilizando Streamlit, permitindo a criação de um dashboard interativo para simulação em tempo real das decisões hospitalares. A visualização de dados foi complementada com a biblioteca Plotly, permitindo a análise dinâmica da evolução dos estados e métricas do sistema.

As principais bibliotecas utilizadas incluem:

- **NumPy**: suporte a operações numéricas e manipulação vetorial dos estados
- **Pandas**: estruturação e armazenamento do histórico de simulação
- **Scikit-learn**: implementação do modelo de regressão linear para previsão de estados
- **Plotly**: geração de gráficos interativos para análise de desempenho
- **Random (Python)**: simulação estocástica das transições de estado

Arquitetura do sistema

A arquitetura do sistema é composta por três módulos principais:

1. Módulo de simulação estocástica (MDP aproximado) Responsável por modelar a evolução do sistema hospitalar através de estados definidos por:

$$s = (o, r, u)$$

onde:

- o: leitos ocupados
- r: recursos disponíveis

- u: nível de urgência

As transições de estado são geradas de forma probabilística através de regras definidas manualmente e amostradas via distribuição discreta.

2. Módulo de avaliação de decisões (função de recompensa e Q-value) Cada ação é avaliada com base numa função de recompensa definida por:

$$R = Eficiência + Satisfação - Custo$$

O valor esperado da ação é calculado por:

$$Q(s, a) = \sum P(s' | s, a) \cdot R(s, a, s')$$

Este valor é utilizado para comparar alternativas de decisão no estado atual.

3. Módulo de aprendizagem supervisionada (Machine Learning) Um modelo de regressão linear é utilizado para prever o próximo estado do sistema com base no estado atual e na ação executada:

$$\hat{s}_{t+1} = f(s_t, a_t)$$

Este módulo não substitui o MDP, mas atua como componente preditivo auxiliar.

2.6.7.1 Natureza da implementação

Importa destacar que o sistema não implementa um MDP resolvido por métodos clássicos de programação dinâmica (como Value Iteration ou Policy Iteration). Em vez disso, trata-se de um modelo simulado baseado em amostragem estocástica, onde as decisões são avaliadas localmente através de valores esperados.

Dessa forma, a abordagem pode ser classificada como um:

- **MDP simulado com avaliação empírica de políticas (simulation-based decision process)**

2.6.8. Escalabilidade e adaptação do modelo para outros hospitais

O modelo desenvolvido apresenta elevada capacidade de adaptação a outros hospitais municipais, uma vez que a sua estrutura é baseada em variáveis genéricas e independentes da instituição específica.

O estado do sistema é definido por:

S=(leitos ocupados,recursos disponíveis, urgência médica)

Esta representação permite a reutilização do modelo em diferentes unidades hospitalares, bastando ajustar os parâmetros operacionais.

2.6.8.1.Adaptação estrutural do modelo

Para a aplicação do sistema em outros hospitais, são necessários apenas os seguintes ajustes:

- Capacidade total de leitos
- Disponibilidade de recursos hospitalares
- Distribuição de urgência dos pacientes
- Regras locais de operação hospitalar

A estrutura do modelo permanece inalterada, o que garante portabilidade do sistema entre instituições de saúde com características semelhantes.

2.6.8.2. Transferibilidade do modelo de Machine Learning

O componente de Machine Learning, baseado em regressão linear supervisionada, não utiliza Transfer Learning profundo, mas permite reutilização estrutural do conhecimento através de re-treinamento com novos dados.

O processo de adaptação ocorre da seguinte forma:

1. O modelo é inicialmente treinado com dados do Hospital Municipal do Nzeto
2. Em novos hospitais, a mesma arquitetura do modelo é reutilizada
3. O modelo é re-treinado com dados locais da nova instituição

Este processo caracteriza uma forma de:

Transferência de conhecimento baseada em re-treinamento supervisionado

2.6.8.3.Escalabilidade computacional e institucional

Do ponto de vista computacional, o sistema é altamente escalável devido à sua arquitetura modular e leve. A separação entre simulação, aprendizagem e visualização permite:

- execução em ambientes locais ou servidores cloud
- expansão para múltiplos hospitais em paralelo

- integração futura com sistemas reais de gestão hospitalar (HIS)

Do ponto de vista institucional, o modelo pode ser estendido para uma rede hospitalar municipal ou provincial, permitindo:

- comparação de desempenho entre hospitais
- análise de ocupação regional de recursos
- suporte à formulação de políticas públicas baseadas em simulação

2.6.8.4. Síntese da escalabilidade

Em síntese, o modelo proposto não se limita ao Hospital Municipal do Nzeto, podendo ser generalizado como um framework de apoio à decisão hospitalar sob incerteza, adaptável a diferentes contextos através de reconfiguração paramétrica e re-treinamento supervisionado.

3. METODOLOGIA MÉTODO E TÉCNICA DE INVESTIGAÇÃO

O presente estudo caracteriza-se como:

- **Pesquisa aplicada**, por buscar soluções práticas e implementáveis no contexto hospitalar.
- **Pesquisa exploratória**, pois visa compreender e modelar um problema complexo, pouco estudado especificamente no Hospital Municipal do Nzeto.
- **Pesquisa quantitativa**, ao simular cenários, calcular probabilidades de transição e determinar funções de valor e políticas ótimas.
- **Pesquisa qualitativa**, ao interpretar os resultados em termos de impacto operacional e segurança do atendimento.

3.1 ABORDAGEM DA PESQUISA

A abordagem adotada combina:

- **Simulação computacional**: modelagem do hospital como um MDP, incluindo estados, ações, probabilidades de transição e recompensas.
- **Análise de cenários**: avaliação das políticas obtidas em situações de alta demanda, baixa demanda e recursos limitados.

- **Revisão bibliográfica:** estudo de casos anteriores de aplicação de MDP em hospitais e literatura sobre otimização de recursos em gestão hospitalar.

3.2 PROCEDIMENTOS DE RECOLHA DE DADOS

Os dados utilizados na pesquisa são coletados a partir de:

- **Registros hospitalares:** histórico de pacientes, número de leitos ocupados, quantidade de pacientes críticos, disponibilidade de médicos e enfermeiros.
- **Entrevistas com gestores:** levantamento de práticas atuais de alocação de recursos e desafios enfrentados no dia a dia.
- **Revisão bibliográfica e documental:** artigos científicos e estudos de caso sobre MDPs e gestão hospitalar.

Esses dados permitem a construção de um **modelo realista de MDP**, refletindo as operações do hospital de maneira precisa e confiável.

3.3 PROCEDIMENTOS DE ANÁLISE DE DADOS

A análise de dados ocorre em duas frentes:

1. **Quantitativa:**

- Modelagem do hospital como um MDP, definindo estados (ocupação de leitos, pacientes críticos, disponibilidade de recursos), ações (admitir, transferir, reagendar) e recompensas (eficiência, segurança, custos).
- Aplicação de algoritmos de **Value Iteration** em Python para calcular a política ótima em cada estado.
- Avaliação de cenários de demanda variável, permitindo identificar decisões estratégicas robustas.

2. **Qualitativa:**

- Interpretação dos resultados do MDP quanto ao impacto operacional, eficiência e segurança do atendimento.
- Comparação das políticas obtidas com as práticas atuais do hospital, identificando oportunidades de melhoria.

3.4 JUSTIFICATIVA DA METODOLOGIA

A metodologia escolhida combina **rigor científico e aplicabilidade prática**, permitindo que o estudo não se limite a conceitos teóricos. A modelagem como MDP oferece uma abordagem estruturada para decisões complexas, garantindo que o Hospital Municipal do Nzeto possa:

- Planejar recursos de forma eficiente mesmo diante da incerteza.
- Minimizar riscos de atendimento inadequado a pacientes críticos.
- Adaptar-se a cenários de alta demanda, como epidemias ou emergências médicas.

Dessa forma, o estudo contribui tanto para **avancar o conhecimento acadêmico** sobre MDPs em gestão hospitalar quanto para **propor soluções práticas e implementáveis** no contexto local.

4. ANÁLISE DE RESULTADOS BASEADA NA SIMULAÇÃO

4.1. GESTÃO HOSPITALAR (MDP SIMPLIFICADO)

A aplicação implementa um modelo de decisão sob incerteza baseado em **Processos de Decisão de Markov (MDP)**, em que os estados são definidos por:

- **Leitos ocupados**
- **Recursos disponíveis**
- **Urgência média dos pacientes**

As ações possíveis são: **admitir pacientes, transferir pacientes, abrir novos leitos e reagendar atendimentos**.

Diferentemente de MDPs completos com programação dinâmica, a aplicação utiliza **valor esperado das ações ($Q(s,a)$)** para guiar a decisão, privilegiando a **recompensa imediata esperada**.

Resultados observados na simulação:

- O sistema sugere ações com base no maior valor esperado $Q(s,a)$.
- Em estados com alta ocupação de leitos, a ação **transferir** é frequentemente favorecida.

- Quando há maior disponibilidade de recursos, **admitir** novos pacientes apresenta melhores resultados.
- A decisão se adapta dinamicamente ao estado atual, refletindo alterações no sistema hospitalar.

Métricas utilizadas:

- Eficiência (taxa de ocupação de leitos)
- Urgência média dos pacientes
- Satisfação (derivada da redução da urgência)
- Custo associado às ações
- Valor esperado das decisões ($Q(s,a)$)

4.2. DINÂMICA HOSPITALAR COM INCERTEZA

A aplicação incorpora **incerteza** por meio de **transições probabilísticas** entre estados, simulando a variabilidade real do hospital:

- Cada ação pode gerar diferentes próximos estados, com probabilidades associadas.
- Permite representar variações na evolução clínica, impacto incerto das decisões e comportamento dinâmico do sistema.

Resultados observados:

- A mesma ação pode resultar em diferentes estados futuros.
- A variabilidade evidencia a necessidade de decisões adaptativas.
- A simulação permite explorar cenários distintos de gestão hospitalar.

Métricas observáveis:

- Evolução dos estados ao longo das decisões
- Frequência de ocorrência de cada estado
- Impacto probabilístico das ações

4.3. SISTEMA INTERATIVO DE APOIO À DECISÃO

O aplicativo funciona como um **dashboard interativo**, permitindo ao usuário:

- Visualizar o estado atual (leitos, recursos e urgência)
- Executar ações com impacto imediato
- Registrar histórico das decisões
- Observar o **valor esperado $Q(s,a)$** para cada ação

Resultados observados:

- Maior compreensão do impacto das decisões tomadas
- Possibilidade de testar diferentes estratégias interativamente
- Apoio à tomada de decisão em ambientes incertos

4.4. APRENDIZAGEM E PREVISÃO (MACHINE LEARNING)

A aplicação integra **regressão linear** para prever estados futuros com base no histórico de decisões.

Resultados observados:

- O sistema aprimora gradualmente a previsão à medida que novas ações são executadas.
- O módulo de **Sugestão Inteligente** recomenda ações com maior recompensa esperada.
- A abordagem combina modelagem matemática (MDP simplificado) com aprendizado de dados.

4.5. VISUALIZAÇÃO DOS RESULTADOS

O dashboard fornece visualizações claras e intuitivas:

- **Indicadores coloridos** (verde, laranja, vermelho) para níveis críticos de leitos, recursos e urgência
- **Tabela de histórico** de decisões, incluindo ação, estado, próxima ação, recompensa e valor esperado $Q(s,a)$
- **Gráfico de linha** mostrando evolução do valor esperado $Q(s,a)$

- **Gráficos de barra** das ações realizadas e métricas detalhadas por ação

Interpretação:

- Valores mais altos de $Q(s,a)$ indicam decisões mais vantajosas
- Variações refletem mudanças no estado do hospital
- Indicadores visuais facilitam identificação rápida de situações críticas

4.6. ANÁLISE DO COMPORTAMENTO DO SISTEMA

A análise dos resultados evidencia decisões sequenciais sob incerteza:

- Estados com baixa ocupação favorecem **admissão de pacientes**
- Estados críticos priorizam **transferência ou reagendamento**
- Disponibilidade de recursos influencia diretamente a escolha da ação
- O sistema adapta-se continuamente às condições atuais

4.7. LIMITAÇÕES DO MODELO

Embora funcional, o modelo apresenta limitações:

- Não realiza iteração de valor ou política para obter uma política ótima global
- As decisões são baseadas apenas na **recompensa imediata esperada**
- Não há simulação contínua automática do sistema
- Métricas hospitalares como tempo de espera ou permanência não são modeladas

4.8. SÍNTESE DOS RESULTADOS

- Representa decisões hospitalares sob incerteza de forma estruturada
- Baseada em $Q(s,a)$, permite escolhas vantajosas no curto prazo
- Simulação estocástica evidencia a variabilidade do sistema
- Aprendizado de máquina adiciona capacidade preditiva
- Dashboard interativo facilita análise e compreensão

4.9. CONSIDERAÇÕES FINAIS

A aplicação constitui uma ferramenta eficaz para apoio à decisão hospitalar:

- Permite explorar cenários, avaliar ações e entender o impacto da incerteza
- Fornece base sólida para futuras extensões, incluindo políticas ótimas e simulações mais complexas

CONSIDERAÇÕES FINAIS

O presente estudo teve como objetivo principal **analisar a aplicação de Processos de Decisão de Markov (MDP)** para desenvolver políticas ótimas de alocação de recursos e leitos no **Hospital Municipal do Nzeto**. A implementação do modelo possibilitou **simular de forma realista a dinâmica hospitalar**, considerando a chegada de pacientes, a ocupação de leitos, a disponibilidade de recursos e o nível de urgência clínica, oferecendo uma ferramenta quantitativa para apoiar decisões estratégicas e operacionais.

A análise demonstrou que o uso de **valores esperados $Q(s,a)$** permite priorizar decisões de forma objetiva, reduzindo riscos de superlotação, complicações clínicas e desperdício de recursos. A simulação fornece **feedback imediato** por meio de alertas automáticos e visualizações intuitivas, permitindo antecipar problemas e otimizar a alocação de recursos antes que situações críticas ocorram na prática.

Em síntese, o estudo confirma que a aplicação de MDP contribui significativamente para a eficiência operacional e o planejamento estratégico do hospital, reforçando a segurança e a qualidade do atendimento aos pacientes. O modelo desenvolvido atende plenamente aos objetivos propostos e evidencia a utilidade de simulações computacionais como ferramentas de apoio à tomada de decisão em ambientes hospitalares complexos.

REFERÊNCIAS BIBLIOGRÁFICAS

Bellman, R. (1957). Dynamic programming. Princeton University Press.

Borba, V. R., & Lisboa, T. C. (2006). Teoria geral de administração hospitalar: Estrutura e evolução do processo de gestão hospitalar. QualityMark.

Cavalcante, A. P. S., Prestes, A., Cardoso, B. B., Miguez, C. Q., Marcial, E. C., Costeira, E., Bitencourt, F., Bicalho, F. C., Lolato, G., Cirino, J. A., Lemos, J. B., Costa, J. F. R., Cruz, P. G., Constantino, P. B., Macedo, R., Aguiar, R. R., Duarte, T., & Júnio,

- V. O. (2020). A gestão da qualidade em saúde. Federação Brasileira de Hospitais.
https://fbh.com.br/wp-content/uploads/2020/11/MANUAL-FBH_web.pdf
- Nunes, L. G. N., Carvalho, S. V., & Rodrigues, R. de C. M. (2009). Markov decision process applied to the control of hospital elective admissions. *Artificial Intelligence in Medicine*, 47(2), 159–171.
<https://www.sciencedirect.com/science/article/abs/pii/S0933336570900116X>
- Prestes, A., Cirino, J. A. F., Oliveira, R., & Sousa, V. (Orgs.). (2020). Manual do Gestor Hospitalar. Federação Brasileira de Hospitais.
https://www.ispsn.org/sites/default/files/documentos-virtuais/pdf/3-manual_do_gestor_hospitalar_2ed_web.pdf
- Puterman, M. L. (2014). *Markov Decision Processes: Discrete Stochastic Dynamic Programming* (2nd ed., 666 pp.). Hoboken, NJ: John Wiley & Sons.
- Ross, S. M. (2014). *Introduction to probability models* (11th ed.). Academic Press.
- Schaefer, A. J., Bailey, M., Shechter, S. M., & Roberts, M. S. (2005). Modeling medical treatment using Markov decision processes. In *Operations research and health care* (pp. 593–612). Springer. https://doi.org/10.1007/1-4020-8066-2_23
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). MIT Press.
- Ultralytics. (s.d.). Glossary: Markov Decision Process (MDP).
<https://www.ultralytics.com/pt/glossary/markov-decision-process-mdp>
- Wang, X., Liang, Z., & Zhu, K. (2021). Markov decision model of emergency medical supply scheduling in public health emergencies of infectious diseases. *International Journal of Computational Intelligence Systems*, 14(1), 1155–1169.
<https://doi.org/10.2991/ijcis.d.210222.002>